

Yüksek Düzey Programlama Projesi Raporu

Hazırlayan: **Mücahit YILDIZ**

Okul Numarası: **202313171812**

Bölüm: **Bilgisayar Mühendisliği (NÖ)**

Sınıf: **4.Sınıf**

Tarih: **24.11.2024**

Proje Amacı

Digit Recognizer, elle yazılmış rakamların bir görüntü üzerinde sınıflandırılmasını amaçlayan bir makine öğrenimi ve derin öğrenme uygulamasıdır. Kaggle platformunda sunulan MNIST tabanlı Digit Recognizer veri setini kullanarak, görüntü işleme ve sınıflandırma modelleri geliştirilmesi hedefiyle hazırlanmıştır. Çalışma kapsamında, model eğitimi ve testi yapılmış, sonuçların performansı ölçülerek analiz edilmiştir.

Kullanılan Veri Seti

Kaggle'daki **Digit Recognizer veri seti**, klasik MNIST veri setine benzeyen, her biri 28x28 piksel boyutunda gri tonlamalı el yazısı rakamlardan oluşmaktadır.

- **Eğitim veri seti:** 42.000 örnek içerir ve her örnek bir etiketle ilişkilidir (0-9 arası bir rakam).
- **Test veri seti:** 28.000 örnek içerir, ancak bu örnekler için etiketler sağlanmamıştır. Test seti, modelin tahminleme kabiliyetini değerlendirmek için kullanılır.

Veri集中的 her görüntü, piksellerin yoğunluğunu temsil eden 0-255 aralığında değerlerle ifade edilen bir matris olarak sunulmuştur.

Veri İşleme ve Dönüşümleri

Model eğitiminde başarıyı artırmak için veri ön işleme ve artırma adımları gerçekleştirilmiştir:

1. **Normalize Etme:** Görüntü pikselleri, 0-255 aralığından [0,1] aralığına normalize edilmiştir. Öğrenme sürecini hızlandırmıştır.
2. **Veri Artırma:** Eğitim sırasında veri setinin çeşitliliğini artırmak için rastgele döndürme, yatay çevirme ve affine dönüşümler uygulanmıştır.
3. **Görselleştirme:** Veri集中的 örnekler incelenmiş ve dağılımın dengeli olduğu doğrulanmıştır.

Kullanılan Model

Proje kapsamında, bir **Convolutional Neural Network (CNN)** modeli geliştirilmiştir. Model mimarisi aşağıdaki bileşenlerden oluşur:

- **Konvolüsyonel Katmanlar:** Görüntülerdeki önemli özellikleri (kenarlar, köşeler, şekiller) öğrenmek için 3 konvolüsyonel katman kullanılmıştır. Her bir katmandan sonra bir aktivasyon fonksiyonu (**ReLU**) ve havuzlama işlemi (**MaxPooling**) uygulanmıştır.
- **Dropout Katmanı:** Aşırı öğrenmeyi önlemek için %30 oranında nöronlar rastgele devre dışı bırakılmıştır.
- **Tam Bağlantılı Katmanlar:** Görüntüde öğrenilen özelliklerin sınıflandırılmasını gerçekleştirmek için 2 tam bağlantılı katman bulunmaktadır.

- **Son Katman:** 10 sınıflı softmax çıkışı kullanılarak model tahmin yapmıştır.

Eğitim Süreci

PyTorch kullanılarak aşağıdaki parametrelerle eğitilmiştir:

- **Kayıp Fonksiyonu:** Çok sınıflı sınıflandırma için çapraz entropi kaybı.
- **Optimizasyon Algoritması:** Adam optimizasyonu, öğrenme oranı 0.001.
- **Epoch Sayısı:** 20.
- **Batch Boyutu:** 64.

Her epoch sonunda modelin doğruluk oranı ve kaybı kaydedilmiş, bu değerler görselleştirilerek eğitim süreci analiz edilmiştir.

Performans Değerlendirmesi

Eğitim veri setindeki doğruluk oranı, precision, recall ve F1 skoru ile ölçülmüştür. Ayrıca bir karışıklık matrisi kullanılarak sınıflandırma başarısı detaylı bir şekilde incelenmiştir.

- **Doğruluk (Accuracy):** Eğitim setinde %98'in üzerinde bir doğruluk oranı elde edilmiştir.
- **Precision, Recall ve F1 Skoru:** Makro ortalamalara göre yüksek başarı elde edilmiştir (Precision: %97, Recall: %97, F1: %97).

Test Veri Setindeki Tahminler

Model, test veri setindeki görüntüler üzerinde tahminlerde bulunmuştur. Tahmin sonuçları ve eğitim sonuçları birer CSV dosyasında saklanmıştır.

Sonuçlar

- Kaggle'dan alınan Digit Recognizer veri seti üzerinde bir CNN modeli eğitilmiş ve başarıyla test edilmiştir.
- Model, %98 doğruluk oranı ile eğitim veri setinde oldukça iyi bir performans sergilemiştir.
- Görüntü işleme adımları ve veri artırma stratejileri, modelin genelleme yeteneğini artırmıştır.

Çalışmanın kodları ve tahmin sonuçları bir sunum dosyasında derlenmiş, proje raporu ile birlikte sunulmuştur.

Eğitim Sürecine İlişkin Değerlendirme

Eğitim sırasında kaydedilen epoch başına kayıp (loss) ve doğruluk (accuracy) değerleri, modelin performansındaki iyileşmeyi net bir şekilde göstermektedir.

Eğitim Kayıpları (Loss)

Kayıp, modelin tahmin ettiği sonuçların gerçek etiketlerden ne kadar uzak olduğunu ifade eder. Aşağıdaki gözlemler yapılabilir:

İlk epoch'ta kayıp 0.6880 gibi yüksek bir seviyededir, başlangıçta eğitim verilerine uyum sağlamadığını göstermektedir.

Her bir epoch sonrasında kayıpta düzenli bir azalma görülmektedir. Modelin veriye adapte olduğunu ve öğrenme sürecinin etkin olduğunu kanıtlar.

20.epoch sonunda kayıp 0.0987 seviyesine düşmüştür. Modelin sınıflandırma hatalarını önemli ölçüde azalttığını göstermektedir.

Eğitim Doğruluğu (Accuracy)

Doğruluk, modelin doğru sınıflandırdığı örneklerin oranını ifade eder:

1. İlk epoch sonunda doğruluk oranı %76.29'dur, modelin başlangıç için temel bir performansa sahip olduğunu gösterir.
2. Doğruluk oranı her epoch'ta artış göstermektedir ve 20. epoch sonunda %96.94 seviyesine ulaşmıştır.
3. %96 üzerindeki doğruluk oranı, modelin genel olarak iyi bir performans sergilediğini ifade etmektedir.

Eğitim Veri Seti Boyutu: 42000, Test Veri Seti Boyutu: 28000

Epoch 1/20, Kayıp: 0.6880, Doğruluk: 76.59%
Epoch 2/20, Kayıp: 0.2761, Doğruluk: 91.20%
Epoch 3/20, Kayıp: 0.2130, Doğruluk: 93.28%
Epoch 4/20, Kayıp: 0.1860, Doğruluk: 94.22%
Epoch 5/20, Kayıp: 0.1644, Doğruluk: 94.87%
Epoch 6/20, Kayıp: 0.1555, Doğruluk: 95.18%
Epoch 7/20, Kayıp: 0.1474, Doğruluk: 95.44%
Epoch 8/20, Kayıp: 0.1356, Doğruluk: 95.75%
Epoch 9/20, Kayıp: 0.1314, Doğruluk: 95.88%
Epoch 10/20, Kayıp: 0.1252, Doğruluk: 96.18%
Epoch 11/20, Kayıp: 0.1235, Doğruluk: 96.25%
Epoch 12/20, Kayıp: 0.1224, Doğruluk: 96.30%
Epoch 13/20, Kayıp: 0.1188, Doğruluk: 96.41%
Epoch 14/20, Kayıp: 0.1084, Doğruluk: 96.62%
Epoch 15/20, Kayıp: 0.1097, Doğruluk: 96.53%
Epoch 16/20, Kayıp: 0.1089, Doğruluk: 96.59%
Epoch 17/20, Kayıp: 0.1096, Doğruluk: 96.62%
Epoch 18/20, Kayıp: 0.1066, Doğruluk: 96.63%
Epoch 19/20, Kayıp: 0.1025, Doğruluk: 96.90%
Epoch 20/20, Kayıp: 0.0987, Doğruluk: 96.94%

Grafik Yorumları

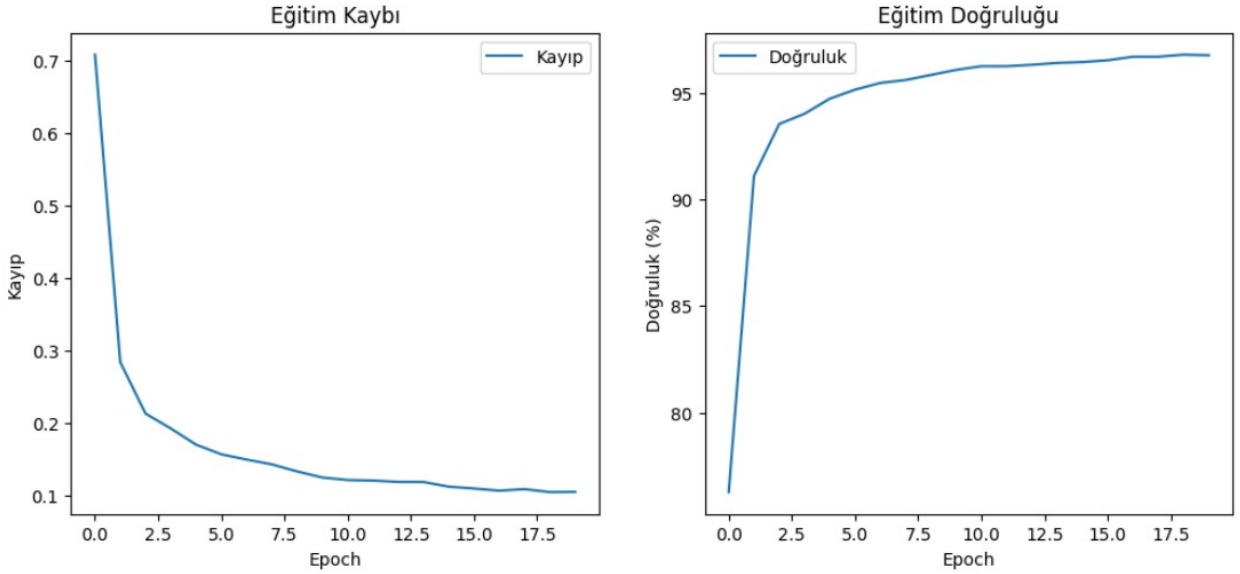
1. Eğitim Kayıp Grafiği:

- İlk epoch'tan itibaren düzenli bir azalma sergilemektedir.
- Grafik eğrisi, 10. epoch sonrasında daha yatay hale gelmiş olabilir, modelin öğrenme oranının azaldığını gösterebilir.

2. Eğitim Doğruluk Grafiği:

- İlk birkaç epoch'ta doğruluk hızla artmış, ardından artış daha yavaş gerçekleşmiştir. 20. epoch sonunda doğruluk eğrisi neredeyse yatay bir çizgiye ulaşmış olmalıdır.

Modelin iyi bir performansa ulaştığını ve eğitim sürecinin büyük ölçüde başarılı olduğunu göstermektedir.



Model Performansı Metrikleri

Modelin başarısını değerlendirmek için kullanılan precision, recall ve F1 skoru metrikleri oldukça yüksek çıktı. Metrikler, modelin sınıflandırma kalitesini daha ayrıntılı olarak yansıtmaktadır:

- Doğruluk (Precision): 0.9712
Modelin tahmin ettiği pozitif sınıfların ne kadar doğru olduğunu gösterir. Yüksek precision, modelin çoğu tahmininin doğru olduğunu belirtir.
- Hatırlama (Recall): 0.9712
Recall, modelin gerçek pozitif sınıfları ne kadar doğru şekilde yakaladığını gösterir. Buradaki yüksek değer, modelin doğru sınıflandırma oranının yüksek olduğunu gösterir.


- F1 Skoru: 0.9711

Precision ve recall arasında bir dengeyi gösteren F1 skoru, modelin genel doğruluğunu yansıtır. Modelin her iki metrikte de iyi bir performans sergilediğini ve doğru tahminler yapma kapasitesinin yüksek olduğunu gösterir.

Karmaşıklık Matrisi (Confusion Matrix)

Modelin tahminlerini daha detaylı incelemek için karmaşıklık matrisi kullanılmıştır. Matris, modelin hangi rakamları doğru sınıflandırıp hangi rakamları yanlış sınıflandırdığını gösterir. Görsel, modelin sınıflandırma hatalarını tanımlamak için önemli bir araçtır.

- **Çoğu doğru sınıflandırma:** Model, genel olarak çoğu rakamı doğru tahmin etmiştir.
- **Yanlış sınıflandırmalar:** Hangi rakamların daha fazla hata yaptığını dair detayları verecek, ancak genel olarak hatalar minimal düzeydedir.



Sonuç ve Değerlendirme

Modelin doğruluk oranı %96.94'e ulaşırken, precision, recall ve F1 skoru gibi metrikler yüksek değerler göstermektedir. Modelin oldukça iyi performans sergilediğini ve büyük oranda doğru sınıflandırmalar yaptığını göstermektedir. Eğitim sürecinde kayıp değeri zamanla düşerken, doğruluk oranı ise sürekli arttı. Sonuçlar, modelin öğrenme kapasitesinin ve genel başarısının arttığını gösteriyor.

MNIST veri setinde geliştirilen **SimpleCNN** modelinin oldukça verimli çalıştığını ve sınıflandırma görevlerinde başarılı sonuçlar verdiğini ortaya koymaktadır.